

# EÖTVÖS LORÁND TUDOMÁNYEGYETEM INFORMATIKAI KAR

### Programozási nyelvek és Fordítóprogramok Tanszék

## Java bytecode interpreter Javában

Témavezető:

Kozsik Tamás Dr.

egyetemi docens

Szerző:

Balázs Zoltán

programtervező informatikus BSc

# EÖTVÖS LORÁND TUDOMÁNYEGYETEM INFORMATIKAI KAR

#### SZAKDOLGOZAT TÉMABEJELENTŐ

Hallgató adatai:

Név: Balázs Zoltán Neptun kód: HV56L5

Képzési adatok:

Szak: programtervező informatikus, alapképzés (BA/BSc/BProf)

Tagozat : Nappali

Belső témavezetővel rendelkezem

Témavezető neve: Kozsik Tamás Dr.

munkahelyének neve, tanszéke: ELTE IK, Programozási nyelvek és Fordítóprogramok Tanszék

munkahelyének címe: 1117, Budapest, Pázmány Péter sétány 1/C.

beosztás és iskolai végzettsége: egyetemi docens, programtervező matematikus

A szakdolgozat címe: Java bytecode interpreter Javában

#### A szakdolgozat témája:

(A témavezetővel konzultálva adja meg 1/2 - 1 oldal terjedelemben szakdolgozat témájának leírását)

A Java nyelvben írt programok fordításuk során nem közvetlenül gépi kódra fordulnak, hanem egy hardver-független nyelvre, amit bytecode-nak neveznek.

Ezt a bytecode-ot az esetek többségében a JVM (Java Virtual Machine) interpreter-e hajtva végre, vagy futási időben fordul le a fordító gép hardverének gépi kódjára.

A szakdolgozat célja egy olyan Java bytecode interpreter fejlesztése, amely képes már előre, valamilyen Java fordító által, elkészített bytecode-ot interpreter-álni, ezt sikeresen (és helyesen) lefuttatni.

A fejlesztett interpreter-nek képesnek kell lennie az ELTE Programtervező Informatikus BSc szakán, különböző, Java-t használó tárgyakon (Programozási nyelvek, Konkurens programozás) elkészített beadandók és házi feladatok generált bytecode-ját interpreter-álni, ezeket helyesen futtatni.

Budapest, 2022. 11. 24.

# Tartalomjegyzék

1.	Bev	ezetés	3
2.	Felh	asználói dokumentáció	5
	2.1.	Kikötések	5
	2.2.	Fordítástól futásig	6
		2.2.1. Minimum követelmények	6
		2.2.2. Fordítás	6
		2.2.3. Futtattás	7
		2.2.4. Önfuttatás	8
	2.3.	Felmerülő problémák	8
3.	Fejl	esztői dokumentáció	9
	3.1.	Class fájl felépítése	9
		3.1.1. Class fájltól a benne levő metódus futtatásáig	9
		3.1.2. Pár minta class fájl felépítése	12
		3.1.3. Adatszerkezetek	14
		3.1.4. Interpretálás működése	16
	3.2.	Az interpreter sajátosságai	17
		3.2.1. Erőforrás igények	17
		3.2.2. A program memóriamodellje	19
		3.2.3. Az önfuttatásról	19
	3.3.	Tesztelő környezet	20
		3.3.1. Tesztelés	20
		3.3.2. Saját teszteset hozzáadása	21
	3.4.	Továbbfejlesztési lehetőségek	21
		3.4.1. Invokedynamic utasítás	21
		3.4.2. Java 7 előtti verziók támogatása	22
		3.4.3 Optimalizálás	າ

#### TARTALOMJEGYZÉK

		3.4.4.	További tesztelés	23						
		3.4.5.	Reflekció újragondolása	24						
	3.5.	Érdeke	ességek a JVM specifikációból	24						
4.	Össz	zegzés		26						
Κċ	iszön	etnyil	vánítás	27						
Iro	Irodalomjegyzék									
Τέ	Táblázatjegyzék									
Fo	rrásk	kódjegy	yzék	30						

# 1. fejezet

### Bevezetés

A Java nyelvben írt programok fordításukat követően nem egy közletlen futtatható állományra (gépi kódra) fordulnak (a fordítást általában a beépített javac program végzi el), hanem egy köztes nyelvre, Java bájtkódra, amelyet aztán különböző programokkal az adott architektúrán interpretáljuk. Legtöbb esetben az interpretálást a JVM (Java Virtual Machine, magyarul Java virtuális gép) interpretere hajtja végre (ez a beépített java program).

A szakdolgozat célja egy kiegészítő program (fantázianevén Jabyinja: Java bytecode interpreter in Java) írása, amely ugyan hagyatkozik a javac és java programokra (az előbbire a fordítás, az utóbbira a futtatás miatt), de a tényleges futtatást a különböző Java bájtkód instrukciók (utasítások) implementálásval végzi el.

A program nincsen Java kód interpretálásához kötve, a Java bájtkód a neve ellenére nem csak a Java programozási nyelvnek a bájtkódja, más programozási nyelveknek is az alapja (ezek közül pár: Clojure, Kotlin, Scala), pontosabban azoknak amelyek a JVM-et használják fel, viszont a tesztelés csak Java kódból generált Java bájtkódra tér ki, ugyanis a szakdolgozat céljaként az ELTE Programtervező Informatikus BSc szakán elkészített Java programok lefordított class fájlainak interpretálását tűztem ki.

A programnak szükséges értelmeznie kell egy adott class fájlt (többet is ha egy külön fájlra is hivatkozunk), helyesen beolvasnia a benne lévő adatokat, majd a belépési (main) metódust lefuttatnia. A program erősen alapszik a Java nyelvbe beépített reflekcióra, ezen felül saját stack és lokális változók implementálása is szükséges. Mivel a Java nyelvre épül a program, ezért saját heap megírására nincsen szükség, ez automatikusan kezelve lesz a standard Java interpreter által.

A program a JVM specifikációt[1] (ennek is a 7-es verizóját) követi, azt megpróbálja tökéletesen implementálni, minden egyes megoldási döntésével (jó vagy rossz) együtt.

## 2. fejezet

### Felhasználói dokumentáció

A program elsődleges felhasználói fejlesztők, alapszintű tudás szükséges a Java nyelvről (vagy bármilyen olyan nyelvről amely Java bájtkódra fordul), a class fájlokról, illetve Java programok fordításáról.

Mivel az elkészített program csak interpretálni tud, a fordítást egy már elérhető Java fordítóprogrammal szükséges megtenni. Mivel a Java programok class fájlokra fordulnak, ezek futtatásához szükséges egy interpretáló program.

Alapvető esetben ez a fordítóprogrammal együtt telepítésre kerül. A szakdolgozat esetében a lefordított class fájl futtatásával képesek lehetünk más, már lefordított Java programot futtatni.

A mellékelt fájlok között elérhető egy jar fájl is, ennek a futtatásához ugyanúgy szükségünk van egy beépített interpretáló programra, amely képes Java programokat futtatni és nem a szakdolgozat maga.

#### 2.1. Kikötések

A program csak Java 7-nél újabb fordítóprogrammal fordított Java programokat képes interpretálni, számos bájtkód instrukciót a Java 7-es verziójában elavulttá tettek (ezek: ret, jsr, jsr\_w), nem fordulnak elő class fájlokban. A szakdolgozat ezeket az instrukciókat nem implementálta. (Implementálásukról részletesebben szó van a fejlesztői dokumentáció "Továbbfejlesztési lehetőségek" szekciójában, implementálásuk viszonylag triviális, viszont megértésük segít elmélyülni a Java bátjkódban.)

Ezen felül egy másik, a Java 7-nél újabb verziójú programokban elég gyakran előforduló instrukció is implementálatlan maradt (név szerint az invokedynamic), tehát

nem minden program futtatható. Ennek az indoka hogy ez az utasítás nagyon nagy szintű elmélyülést igényel a Java bájtkódban, értelmezése meghaladja egy szakdolgozat szintjét. Ez az instrukció önmagában használható arra hogy egy, a szakdolgozat témájához hasonló, Java bátjkód interpretert írjon az ember. Ha a class fájlok egyike tartalmazza ezt az instrukciót, akkor a program jelez a felhasználó számára. Akaratlanul is része lehet a programunknak ez az instrukció, amikor egy változót szöveggel együtt próbálunk kiírni:

```
public class InvokeDynamic {
  public static void main(String[] args) {
    String world = "world";
    System.out.println("Hello " + world);
}
```

2.1. forráskód. invokedynamic utasítást tartalmazó Java kód

akkor a legtöbb fordítóprogram egy invokedynamic utasítást is elhelyez a programunkban.

Ez viszont elkerülhető, ha megfelelő flagekkel fordítjuk le a programunkat, mégpedig a -XDstringConcat=inline flag használatával az invokedynamic nem fog szerepelni a string konkatenációnál.

#### 2.2. Fordítástól futásig

#### 2.2.1. Minimum követelmények

A program fordításához legalább a Java 17-es verziója szükséges. Ez alatt a program fordulni sem képes, mivel pár olyan funkciót használ, amely csak a 17-es verzióban lett bevezetve.

A könnyebb fordítás (illetve egyszerűbb jar fájl készítés) érdekében a Maven fordítás automatizálási program telepítése ajánlott, ezen belül is a 3.9.0-ás verzió.

#### 2.2.2. Fordítás

Ha nem akarunk Maven-t használni, akkor a fordítás menete a következő:

 Menjünk a src/main/java mappába (a \$ jel arra utal, hogy normál felhasználóként futtassuk a parancsot):

```
s cd src/main/java/
```

• Fordítsuk le a com/zoltanbalazs/Main.java fájlt:

```
$ javac com/zoltanbalazs/Main.java
```

- Az elkészült class fájl a src/main/java/com/zoltanbalazs mappában lesz
   Maven-t használva ez a procedúra egyszerűbb:
- Futtassuk le a csomagoló parancsot:

```
1 $ mvn package
```

• Az elkészült class fájl a target/classes/com/zoltanbalazs mappában lesz, ezen felül a target mappában lesz egy futtatható jar fájl is

#### 2.2.3. Futtattás

Ha a generált class fájllal akarjuk futtatni a programot, futtassuk le a java com. zoltanbalazs.Main parancsot a src/main/java mappában. (ha Maven-nel fordítottunk akkor a target/classes mappában futtassuk le az előző fenti parancsot)

A maven által készített jar fájllal való futtatáshoz, futtassuk le a java -jar target /jabyinja-1.0.0.jar parancsot a főmappában.

Mindkét esetben egy opcionális argumentumot (argumentum sorozatot ha a futtatandó programunk vár parancssori argumentumot) meg tudunk adni, ez a main metódust tartalmazó class fájl elérési útvonala. Alapvető esetben a program a futási mappában próbál meg egy Main.class fájlt futtatni.

Futásra egy példa:

```
$ java -jar target/jabyinja-1.0.0.jar

target/test-classes/com/zoltanbalazs/PTI/_01/Greet.class World
```

#### 2.2.4. Önfuttatás

Az elkészült interpreter képes saját magát is futtatni, ehhez a futtatáshoz hasonlóan meg kell adni a programnak a saját class fájlának elérési útját, majd opcionálisan a többi paramétert.

Ez a futtatás jar fájl esetén így néz ki, a főkönyvtárból futtatva:

- \$ java -jar target/jabyinja-1.0.0.jar
  - → target/classes/com/zoltanbalazs/Main.class
  - → target/test-classes/com/zoltanbalazs/PTI/\_01/Greet.class World

#### 2.3. Felmerülő problémák

A futtatandó program futása során nem merül fel probléma (hacsak nincsen invokedynamic a generált class fájlban) amelyet a program okoz. Ha a futtatandó programunk hibát dob, akkor ezt az interpretáló program is ugyanúgy megteszi; viszont a hiba kiírása során nem biztos hogy ugyanazt a kimentet kapjuk mint a beépített interpreterrel.

Tehát ha a hibánk nem egy try, catch blokk-ban szerepel, akkor a kiírt üzenet nem biztos hogy ugyanaz lesz mint a beépített interpreterrel, az összes többi kiírt üzenet viszont ugyanaz kell hogy legyen.

# 3. fejezet

## Fejlesztői dokumentáció

A program számos segítséget ad fejlesztőknek a kód egyszerű értelmezésére; a kód bővítésére. Vállalkozó szellemű embereknek a program egy teljes Java interpretert tud nyújtani viszonylag kevés továbbfejlesztéssel. A Java bájtkód instrukciók megértése során bármely Java fejlesztő jobban tudja értékelni hogy mit is csinál a Java fordítóprogram a háttérben. A program nagyon szorosan épül a JVM specifikációra, a specifikációt annak megfelelően próbálja implementálni.

#### 3.1. Class fájl felépítése

#### 3.1.1. Class fájltól a benne levő metódus futtatásáig

A fő osztály a ClassFile, ez felel számos dologért, többek között egy class fájl beolvasáért, a megfelelő adattagok beállításával. A ClassFile osztálynak egy konstruktora van, mégpedig:

```
public ClassFile(String fileName, String[] mainArgs)
```

Tehát az első paraméter a beolvasandó class fájl neve, a második pedig a main metódusnak adott argumentumok.

Az implementáció alapján nem kötött a main metódus használata belépési pontként, tehát a 2. argumentum lehet null is.

A konstruktor meghívása egyidejüleg meghívja a readClassFile függvényt is:

```
public void readClassFile(String fileName)
```

Ez a függvény egy adott fájlnévre beolvassa a class fájlban tárolt adatokat megfelelő változókba. (Ezen felül egy VALID\_CLASS\_FILE változót is beállít; feltétellezük hogy ha a mágikus szám (CA FE BA BE) megtalálható a fájl elején, akkor az adott fájl egy valid class fájl, ellenkező esetben egy InvalidClassFileException-t dob a beolvasó függvény.)

A beolvasás után (tehát az objektum létrehozása után) érdemes a belépési függvényt (általában main) megkeresni a findMethodsByName metódussal:

```
public Method_Info findMethodsByName(String methodName)
```

Ez egy adott függvénynévre a megfelelő nevü metódust visszaadja a beolvasott fájlból (ha nem talál ilyet akkor null-t ad vissza). Egy példa a használatára:

```
ClassFile CLASS_FILE = new ClassFile("Main.class", null);

Method_Info method = CLASS_FILE.findMethodsByName("main");
```

A függvény megtalálása után ajánlott a Code attribútumot megtalálni, ebben, többek között, található a futtatandó Java bájtkód is. A segédfüggvény erre a findAttributesByName:

Mivel egy attribútumból több is lehet, egy listát kapunk vissza (a Code-ból csak egy lesz), bemeneti paraméterként az attribútumnév mellett a megfelelü függvény attribútumait is át kell adnuk, például:

```
List<Attribute_Info> attributes =

CLASS_FILE.findAttributesByName(method.attributes, "Code");
```

(Ha nem talál ilyen nevezetű attribútumot akkor üres listát ad vissza.)

A megfelelüen beolvasott attribútum után, a megtalált attribútumok között ajanlott végigmenni, a List implementálja az Iterable-t, így egy for ciklussal elegánsan megtehetjük ezt:

```
for (Attribute_Info attribute : attributes)
```

Mivel Code attribútumokról beszélünk, ezért a következő ajánlott dolog hogy ebből az attribútumból olvassuk be az adatokat. Ehhez a Code\_Attribute\_Helper osztály readCodeAttributes metódusa megfelelő:

A függvény egy attribútumot vár (például az előbbi kódrészlet attribute változóját), majd pedig beolvassa a specifikációnak megfelelően a Code\_Attribute-ot, és visszaadja azt, ha valamiért nem sikerült a beolvasás akkor IOException-t dob a függvény.

```
Code_Attribute codeAttribute =

    Code_Attribute_Helper.readCodeAttributes(attribute);
```

Ezt a beolvasott attribútumot a ClassFile osztály fel tudja használni az executeCode metódusával, mely egy byte[] változót vár bemeneti paraméterként, ami a Code\_Attribute része:

```
public Pair<Class<?>, Object> executeCode(byte[] code) Throwable
```

A reflekció miatt számos hibát dob vissza a függvény, ha nem helyes a kód formátuma akkor IOException-t dob a függvény, a Throwable az ATHROW Java bájtkód instrukció miatt szükséges (ekkor egy hibát dob vissza a metódusunk). Visszatérési értéke Pair<Class<?>, Object>, a számos RETURN utasítás miatt (ezeket a stack-en szükséges elhelyezünk) Példa a használatára:

```
CLASS_FILE.executeCode(codeAttribute.code);
```

Ezzel el is jutottunk egy class fájl beolvasásától, az abban lévő adott függvény Java bájtkódjának futtatásáig, több teendőnk nincsen, a program az adott függvényben levő külön függvényhívásokat automatikusan elvégzi.

A teljes példakód:

```
public class Interpreter {
    public static void main(String[] args) throws Throwable {
      ClassFile CLASS_FILE = new ClassFile("Main.class", null);
      Method_Info method = CLASS_FILE.findMethodsByName("main");
      List < Attribute_Info > attributes = CLASS_FILE.
         findAttributesByName(method.attributes, "Code");
6
      for (Attribute_Info attribute : attributes) {
7
        Code_Attribute codeAttribute = Code_Attribute_Helper.
           readCodeAttributes(attribute);
        CLASS_FILE.executeCode(codeAttribute.code);
9
      }
10
    }
11
12 }
```

3.1. forráskód. Példa a Main.class interpretálására

#### 3.1.2. Pár minta class fájl felépítése

A legegyszerűbb class fájl ami értelmes, viszont nem futattható:

Java kódban ennek megfelelője az üres fájl:

Class fájl formátumának magyarázata:

- CA FE BA BE: Mágikus szám, amely minden Class fájl elején megtalálható
- 00 00 00 00: Class fájl Minor és Major verziószáma, egy táblázatnak megfelelően a fordítóprogram verziója
- 00 00: A Constant Pool mérete (+1, mivel 1-től indexelt, itt nem számít)
- 00 00: Hozzáférési zászlók ()
- 00 00: This osztály indexe a Constant Pool-ban
- 00 00: Super osztály indexe a Constant Pool-ban

- 00 00: Interfészek száma
- 00 00: Adattagok száma
- 00 00: Függvények száma
- 00 00: Osztály attribútumainak száma

A legegyszerűbb class fájl amit a *Jabyinja* program le tud futtatni (a beépített java program nem képes ezt lefuttatni, mivel nincsenek benne osztályok, a JVM specifikáció alapján az osztályok elhanyagolhatóak):

```
CA
     FE
          BA
               BE
                     00
                          00
                               00
                                   00
                                                                    6F
                                        00
                                             04
                                                 01
                                                      00
                                                           04
                                                               43
64
     65
                00
                                   69
                                        6E
                                             01
                                                  00
          01
                     04
                          6D
                               61
                                                      03
                                                           28
                                                               29
                                                                    56
00
     21
          00
                00
                     00
                          00
                                        00
                                             00
                                                 00
                                                      01
                                                           00
                                                               09
                                                                    00
                               00
                                   00
02
     00
          03
                00
                     01
                          00
                               01
                                   00
                                        00
                                             00
                                                 0D
                                                      00
                                                           00
                                                               00
                                                                    00
00
     00
                                   00
          00
                01
                     B1
                          00
                               00
                                        00
```

Java kód megfelelője:

```
public static void main() {
    return;
}
```

Class fájl formátumának magyarázata:

- CA FE BA BE: Mágikus szám, amely minden class fájl elején megtalálható
- 00 00 00 00: Class fájl Minor és Major verziószáma, egy táblázatnak megfelelően a javac fordítóprogram verziója
- 00 04: A Constant Pool mérete (+1, mivel 1-től indexelt)
- 01 00 04 43 6F 64 65 01 00 04 6D 61 69 6E 01 00 03 28 29 56: Constant Pool

```
- 01 00 04 43 6F 64 65
```

01: Constant Pool Info érték (CONSTANT\_Utf8)

00 04: 4 hosszú

43 6F 64 65: A CONSTANT\_Utf8 értéke: Code

- **01** 00 04 6D 61 69 6E

01: Constant Pool Info érték (CONSTANT\_Utf8)

00 04: 4 hosszú

6D 61 69 6E: A CONSTANT\_Utf8 értéke: main

- 01 00 03 28 29 56

01: Constant Pool Info érték (CONSTANT\_Utf8)

00 03: 3 hosszú

28 29 56: A CONSTANT\_Utf8 értéke: ()V

```
• 00 21: Hozzáférési zászlók (Public, Super) - elhanyagolhatóak ebben az esetben
• 00 00: This osztály indexe a Constant Pool-ban
• 00 00: Super osztály indexe a Constant Pool-ban
• 00 00: Interfészek száma
• 00 00: Adattagok száma

    00 01: Függvények száma

• 00 09 00 02 00 03 00 01 00 01 00 00 0D 00 00 00 00 00 00 00 01 B1 00 00
  00 00: Függvények
    - 00 09 00 02 00 03 00 01 00 01 00 00 0D 00 00 00 00 00 00 00 01 B1 00
      00 00 00
      00 09: Hozzáférési zászlók (Public, Static)
      00 02: Constant Poolban lévő indexe a függvénynek: main
      00 03: Függvény leírása (bemeneti paraméterek, visszatérési érték): ()V
      00 01: Függvény attribútumainak száma
      00 01 00 00 00 0D 00 00 00 00 00 00 01 B1 00 00 00 00: Attribútumok
         • 00 01 00 00 00 0D 00 00 00 00 00 00 01 B1 00 00 00 00
           00 01: Constant Pool-ban lévő indexe az attribútumnak: Code
           00 00 00 0D: Attribútum hossza (op = 13 bájt)
           00 00 00 00 00 00 00 01 B1 00 00 00 00: Attribútum
            - 00 00 00 00 00 00 00 01 B1 00 00 00 00
               00 00: Stack mérete
              00 00: Lokális változók száma
              00 00 00 01: Kód hossza
              B1: Kód (B1 = return)
              00 00: Kivételek száma
              00 00: Attribútum attribútumainak száma
• 00 00: Osztály attribútumainak száma
```

#### 3.1.3. Adatszerkezetek

A class fájlnak megfelelően a két legfontosabb adattag a stack és a local (lokális) változók. A különböző instrukciók az ezeken lévő adatokkal dolgoznak, erre/ebbe helyeznek el megfelelő adatokat.

Az egyszerűség kedvéért a stack reprezentációjában az osztály típusát is elmentjük, a két adattag Java reprezentációja a ClassFile osztályban:

```
public List<Pair<Class<?>, Object>> stack = new ArrayList<>();
public Object[] local = new Object[65536];
```

(A Pair egy egyedi osztály, mely két adattagot tud eltárolni, más nyelvekben tupleként is ismeretes.)

A lokális változók maximális mennyiségét előre tudjuk, ez nem lehet több mint egy 16-bites előjel nélküli szám ( $2^{16}=65536$ ), alapból ennek az értéke egy 8-bites előjel nélküli szám ( $2^8=256$ ) lenne, mivel a store és load utasításokat csak egy 8-bites előjel nélküli szám (az index) követi, viszont a wide utasítással a store és load utasítások módosíthatóak, hogy 2 db 8-bites előjel nélküli számot olvassanak be, tehát lényegében egy 16-bites előjel nélküli számot.

Gyakorlatban ez a szám csökkenthető lenne, tudhatjuk hogy futási időben mennyi lokális változója (illetve a stack nagyságát is tudhatjuk, tehát tömbként is reprezentálhatnánk) van egy metódusnak. Ez bővebben le van írva a továbbfejlesztési lehetőségekben.

Kényelmi szempontból létezik a CodeIndex osztály, amely lényegében egy int szám absztrakciója:

```
class CodeIndex {
      private int index = 0;
3
      public void Inc(int value) {
4
           index += value;
      }
6
      public int Next() {
           return index++;
      }
10
11
      public void Set(int value) {
12
           index = value;
13
      }
14
15
      public int Get() {
16
           return index;
17
      }
18
19 }
```

3.2. forráskód. A Codeindex osztály, amely a kód bájttömb jelenlegi indexét tárolja

Az absztrakció oka hogy függvényeknek átadva lehessen módosítani ezt a számot; a szám a jelenlegi index a kódot reprezentáló byte tömbben, megmondja hogy a tömbben lévő melyik indexen levő instrukciót kell végrehajtani.

Az absztrakció különösen észrevehető amikor az if és goto utasításokat hajtjuk végre, a ClassFile objektumunk lokális változója módosítható az Instructions osztály metódusain keresztül. Mivel a Java érték szerint adja át a paramétereket, ez egy sima int számmal nem lehetne megoldani.

#### 3.1.4. Interpretálás működése

Az algoritmus alapján az interpretálás viszonylag egyszerűen működik.

- 1. Olvassuk be a jelenlegi indexen lévő utasítást
- 2. A specifikáció alapján olvassuk be a megfelelő darabszámú extra paramétert
- 3. Végezzük el az utasításnak megfelelő műveletet; módosítsuk a lokális változókat és a stack-et
- 4. Ismételjük az 1. pontot amíg nem vagyunk a kódot tartalmazó bájttömb végén

Természetesen valóságban egy kicsit komplikáltabb ennél a működés (bár nem sokkal). Az utasítások nagy része ténylegesen leírható ezzel az egyszerű 4 lépéses "algoritmussal". A komplikáltabb utasítások viszont a invoke\*, put\*, get. Ezeknél a stack-nek megfelelően kell lekérnünk az adatokat, majd a Java nyelv sajátossága miatt (illetve a reflekció használata miatt) le kell kérnünk a megfelelő metódust, és a paraméterrekkel együtt meghívni / interpretálni a függvényt az interpreterrel.

A fő interpretálást végrehajtó kód a ClassFile osztályban az executeCode metódus.

```
switch (Opcode.opcodeRepresentation(opCode)) {
     ...
}

throw new Throwable("Code did not contain a return statement");
}
```

3.3. forráskód. Az interpretálásért felelős kódrészlet

### 3.2. Az interpreter sajátosságai

#### 3.2.1. Erőforrás igények

A Linux operációs rendszeren beépített time programot (illetve a hyperfine programot) használva az erőforrás igények a tesztfájlokra az alábbiak (a tesztelt számítógép releváns specifikációi: Intel Core i7-8700k processzor 4.7 GHz-en, 16 GB DDR4 memória 2133 MT/s sebességgel):

TD+64 21	/usr/b	oin/java	Jabyinja				
Tesztfájl	Memória	Futási idő	Memória	Futási idő			
Own/Arithmetic.class	37,1 MB	21,4 ms	47,6 MB	92,8 ms			
Own/Arrayclass.class	34,9 MB	20,9 ms	54,6 MB	130,8 ms			
Own/Arraylist.class	37,2 MB	21,4 ms	49,6 MB	87,1 ms			
Own/Athrow.class	34,6 MB	20,4 ms	46,9 MB	61,7 ms			
Own/Dup2.class	36,3 MB	20,3 ms	39,2 MB	45,6  ms			
Own/Inheritence.class	34,8 MB	20,7 ms	51,9 MB	98,1 ms			
Own/Instanceof.class	38,8 MB	20,2 ms	43,1 MB	64,2 ms			
Own/Multianewarray.class	34,4 MB	20,6 ms	47,7 MB	62.9  ms			
Own/Nested.class	39,3 MB	22,1 ms	47,2 MB	80,5  ms			
Own/Ownclass.class	37,5 MB	20,2 ms	61,9 MB	135,5  ms			
Own/SwitchAthrow.class	36,8 MB	20,5 ms	40,5 MB	43,9 ms			
Own/Template.class	39,2 MB	21,2 ms	51,9 MB	86.5  ms			
PTI/_01/Euler.class	39,5 MB	22,1 ms	47,5 MB	66,4 ms			
PTI/_01/Factorial.class	39,6 MB	21,8 ms	50,7 MB	68,4 ms			

Th464 :1	/usr/b	oin/java	Jabyinja					
Tesztfájl	Memória	Futási idő	Memória	Futási idő				
PTI/_01/GCD.class	38,9 MB	20,6 ms	51,6 MB	67,8 ms				
PTI/_01/Greet.class	38,8 MB	20,8 ms	50,8 MB	56,8 ms				
PTI/_01/Half.class	39,6 MB	22,7 ms	50,7 MB	69,7 ms				
$PTI/_01/Odd.class$	38,5 MB	20,7 ms	37,8 MB	69,7 ms				
PTI/_01/PerfectNum.class	38,8 MB	20.7  ms	51,2 MB	57,1 ms				
PTI/_01/PerfectNumRange.class	37,8 MB	20,6 ms	70,6 MB	87,6 ms				
PTI/_01/Print.class	41,1 MB	21,4 ms	51,2 MB	67,2 ms				
PTI/_01/Sqrt.class	35,7 MB	22,3 ms	50,9 MB	70,3 ms				
PTI/_01/SquareRoot.class	37,6 MB	22,4 ms	43,1 MB	71,5 ms				
PTI/_01/TwoNum.class	35,1 MB	20,6  ms	47,7 MB	75,8 ms				
PTI/_02/_01/PointMain.class	41,5 MB	22,3  ms	55,6 MB	122,7 ms				
$\boxed{ \text{PTI}/\_02/\_02/\text{CircleMain.class} }$	41,5 MB	21,3 ms	53,1 MB	82,5 ms				
$\boxed{ \text{PTI}/\_02/\_03/\text{CircleMain.class} }$	41,3 MB	22,7  ms	55,1 MB	93,7 ms				
$PTI/_02/_04/ComplexMain.class$	41,5 MB	21,2 ms	58,4 MB	125,7  ms				
$PTI/_02/_05/Line Main.class$	41,4 MB	20.7  ms	56,7 MB	102,5 ms				
$PTI/_03/Iterletter Main.class$	41,7 MB	20,8 ms	78,9 MB	180,5  ms				
PTI/_04/_01/PointMain.class	39,6 MB	22,7 ms	58,8 MB	126,7 ms				
$\fbox{ PTI/\_04/\_02/Double Vector Main. class}$	41,3 MB	21,1 ms	68,5 MB	176,2 ms				
$PTI/_05/_01/Swap.class$	41,2 MB	20,1 ms	51,9 MB	60,5  ms				
$\fbox{ PTI/\_05/\_02/IntegerMatrixMain.class}$	41,2 MB	20.7  ms	46,8 MB	70,1 ms				
$\fbox{ PTI/\_05/\_03/WildAnimalMain.class}$	41,0 MB	21,2 ms	73,4 MB	183,5  ms				
$\fbox{ PTI/\_05/\_04/IntVectorMain.class}$	43,2 MB	21,0 ms	53,9 MB	93,9 ms				
$\boxed{ \text{PTI}/\_06/\_01/\text{Calculator.class} }$	39,1 MB	21,1 ms	51,6 MB	64,1 ms				
$\fbox{ PTI/\_06/\_02/AddByLine.class}$	41,2 MB	21,6  ms	53,0 MB	92,3 ms				
$\fbox{ PTI/\_06/\_03/IsPartOf.class}$	39,3 MB	22,4 ms	51,8 MB	73.9  ms				
PTI/_06/_04/CircleMain.class	41,3 MB	22,0 ms	64,7 MB	124,8 ms				
PTI/_08/_01/BookMain.class	41,4 MB	21,4 ms	74,3 MB	197,6 ms				
PTI/_08/_02/CoffeeShop.class	41,1 MB	21,2 ms	60,8 MB	123,7 ms				
PTI/_09/_01/Divisors.class	41,2 MB	20,2  ms	52,2 MB	85,4 ms				
PTI/_09/_04/MultiSetMain.class	41,4 MB	21,6 ms	67,7 MB	$175,4~\mathrm{ms}$				
$\boxed{ \text{PTI}/\_10/\_01/\text{Extends.class} }$	41,4 MB	20,6 ms	52,6 MB	82,4 ms				

Tesztfájl	/usr/b	oin/java	Jabyinja					
Tesztiáji	Memória	Futási idő	Memória	Futási idő				
PTI/_10/_02/BookMain.class	41,1 MB	22,3 ms	85,0 MB	254,5 ms				
$PTI/\_10/\_03/BagMain.class$	41,4 MB	21,4 ms	72,7 MB	175,2  ms				
$PTI/\_10/\_04/Swap.class$	41,6 MB	20,3  ms	53,6 MB	101,0 ms				
$PTI/\_11/\_01/Flying Main.class$	41,4 MB	21,5 ms	54,3 MB	92,0 ms				
$PTI/_11/_02/Main.class$	41,3 MB	20,8 ms	71,6 MB	153,7  ms				
$PTI/\_11/\_03/AnimalMain.class$	41,6 MB	20,5  ms	52,1 MB	78,3 ms				
PTI/_11/_04/AnimalMain.class	41,3 MB	21,7 ms	64,5 MB	152,3 ms				
PTI/_12/Inheritence.class	41,6 MB	20,2 ms	47,7 MB	68,3 ms				

3.1. táblázat. A beépített java és az interpreter közötti erőforrás különbségek

#### 3.2.2. A program memóriamodellje

A heap memória nincsen implementálva a programban. Ez alapszik a standard Java interperet implementációjára. Ide tartoznak többek között az objektumoknak a referenciái. Ebből következően a szemétgyűjtés (garbage collector) a beépített Java szemétgyűjtő algoritmust alkalmazza.

A stack memória fontos építőeleme a programnak, az implementációja ArrayList osztállyal van megoldva.

```
public List<Pair<Class<?>, Object>> stack = new ArrayList<>();
```

Ez az ArrayList egy Class<?>-t és Object-et tartalmazó Pair-eket (tuple) foglal magába. Az Object a konkrét érték amit a stack-en tárolni szeretnénk, a Class<?> egy kényelmi megoldás miatt a tárolt értéknek a típusa.

Az implementációból következően lényegében a tényleges program-ban az alábbi memóriaeloszlás következik be:

#### 3.2.3. Az önfuttatásról

Habár a program tényleg képes önmagát lefuttatni, a Java programozási nyelvet mélyebben értő emberek észrevehetik, hogy ez egy erősen kikötéses állítás. Mivel a

beépített osztályokat nem interpretálja a program, ezért amikor egy olyan parancsot hívunk meg, mint például:

\$ java -jar target/jabyinja-1.0.0.jar

- → target/classes/com/zoltanbalazs/Main.class
- → target/test-classes/com/zoltanbalazs/PTI/\_01/Greet.class World

akkor igazából csak az interperet main metódusáig interpretáljuk azt.

A java beépített interperet működése miatt amikor egy jar fájlt futtatunk, minden, a jar fájlban lévő, osztály beépített lesz. Az eddig leírtak alapján pedig a beépített osztályok metódusai pedig reflekcióval vannak meghívva.

Természetesen a main függvényben is megfelelően kell felépíteni a különböző adattagokat, tehát az interpret tényleg saját magát futtatja, viszont nem látunk akkora erőforrásbeli különbséget mint ami a beépített interpretert és a megírt program között van.

#### 3.3. Tesztelő környezet

A tesztelő környezet egy átlagos Java tesztelő (pl. JUnit) helyett egy saját Python szkript. Az előnye ennek az, hogy a tesztelésnél többet is tud ez a szkript; például a memóriahasználatot, és a futási idő különbséget is mérni. A tesztelő szkript a src/test/tester.py fájlban elérhető. A szkript futtatásához legalább Python 3-as verzió szükséges. A tesztelő működésileg megnézi hogy a beépített Java interpreter, és a megírt interpreter kimenetei megegyeznek-e, ha igen akkor helyesen futott le az interpret, ha nem, akkor helytelenül. Jelen esetben 3 teszteset van, amelyek nem mennek át a tesztelőn, ezek mindegyike tartalmaz invokedynamic utasítást.

#### 3.3.1. Tesztelés

A tesztelőt nagyon egyszerűen meg lehet hívni a

#### \$ python3 src/test/tester.py

paranccsal

Fontos: Ha mindegyik teszteset megbukik akkor nincsen fordított állomány! A tesztelő feltételezi hogy jar fájlként van fordítva a program, amely a target mappában van elhelyezve.

#### 3.3.2. Saját teszteset hozzáadása

Nagyon egyszerűen adható saját teszteset hozzá a szkripthez.

- 1. Helyezzük el a tesztesetet a src/test/java/zoltanbalazs/0wn mappába
- 2. Nyissuk meg a tesztelő szkriptet
- 3. Adjuk hozzá a megfelelő own\_ névvel kezdődő listához a saját tesztesetünket
- 4. Ha van, határozzuk meg a bemeneti argumentum(ok) és/vagy standard bemenetről kapott értékek mennyiségét és típusát
- 5. A következő futtatásnál az új teszteset le fog futni

#### 3.4. Továbbfejlesztési lehetőségek

#### 3.4.1. Invokedynamic utasítás

Az egyik legszembetűnőbb hiány a szakdolgozatban az egyik nem implementált utasítás, az invokedynamic, hiánya. Ez az utasítás számos helyen előfordul Java programokban, leginkább a lambda kifejezésekben (ezen belül is a Konkurens programozás tárgyon megismert Executor osztály paramétereként), illetve a kiírás során szöveg(ek) és változó(k) konkatenációjánál is ez használt.

Az utóbbi egyszerűen kiküszöbölhető a -XDstringConcat=inline flag-gel való fordítás során az invokedynamic utasítás lecserélődik StringBuilder-en keresztül lévő invokevirtual és invokespecial hívásokra.

Az előző viszont sajnos jelen állapotban nem megoldott, és nem is oldható meg egyszerűen. Ahhoz hogy lambda függvények működjenek, az invokedynamic-ot implementálni kell. Ehhez már az alapvető előkészület megvan, a class fájlban lévő bootstrap metódusok egy külön adattag elemeiként el vannak helyezve. A továbbfejlesztés során csak a megfelelő CallSite helyet, illetve a class fájlban lévő constant pool általi index-eken levő metódusokkal (illetve paraméterekkel) kell meghívni az éppen leírt függvényt.

#### 3.4.2. Java 7 előtti verziók támogatása

Viszonylag egyszerűen továbbfejleszthető a program hogy Java 7 előtti verzióval fordított class fájlokat is támogasson.

A hiányzó utasítások a ret, jsr, jsr\_w, ezek mindegyikéhez csak az szükséges, hogy a megfelelő index-re ugorjunk, a jsr és jsr\_w utasítások során a visszatérési címet pedig a stack-re helyezzük.

Természetesen mindegyik utasítás során a megfelelő index-et is be kell olvasnunk a class fájlból, amely a lokális változó megfelelő indexére (ret), vagy egy adott számot (jsr, jsr\_w) határoz meg, amely a visszatérési cím, illetve az ugrási cím.

#### 3.4.3. Optimalizálás

A futási idő táblázata alapján látható hogy a program exponenciálisan lassabb, mint a beépített java interpretáló program. A program több memóriát is igényel mint szükséges lenne. Ezeknek számos oka is van, ezek közül pár:

- A nem beépített osztályok megfelelő konstruktorait minden egyes alkalommal a program egyesével keresi ki a program. Ez a limitáció nagyon szembetűnő ha sok saját osztállyal dolgozunk. Ilyenkor a futási idő exponenciálisan lassul. Egy lehetséges megoldás erre hogy a megfelelő konstruktorokat elmenti a program, majd keresés előtt az elmentett konstruktorok között megnézzük hogy szerepele már a jelenleg hívandó konstruktor. Ha igen, akkor egyértelmű módon nem keressük ki, hanem felhasználjuk azt, ha nem, akkor pedig megkeressük.
- A local változóknak maximális értéket (65536) foglal a program minden nem beépített függvény meghívása során, viszont a class fájlban ennek a maximális értéke le van írva a megfelelő függvény attribútumaként. Tehát a megoldás erre viszonylag egyszerű, függvényfuttatás előtt kellene a lokális változók mennyiségét beállítani. Ennek a problémának a másik verziója, hogy habár a stack egy LIFO (Last In First Out, amely adat utoljára kerül bele, az kerül elsőnek ki belőle) adatszerkezet, a maximális mérete ennek is a class fájlban a függvény egy megfelelő attribútumaként jelen van. A már megírt függvényekkel viszonylag triviális ezt lekérdezni. (A megfelelő függvény a ClassFile osztályban található findAttributesByName)
- A különböző class fájlok beolvasásának eredménye nincs elmentve, ha egy fájlt be kell olvasnunk, akkor azt minden egyes alkalommal külön-külön megte-

szünk, ha az eredményt elmentenénk akkor drasztikusan lehetne a sebességen gyorsítani. Ennek megoldásaként a Main osztályban egy listában fel lehetne venni a beolvasott class fájlokat, egy nem beépített class fájlban levő metódus interpretálása előtt pedig végig lehetne menni a már beolvasott fájlokon. Ezzel jóval kevesebb fájl beolvasás műveletet végeznénk, cserébe a listán való végigmenés lehet hogy kevés class fájl használata esetén negatív hatással lenne.

• A reflekciót újragondolva, azt elhagyva a sebesség növelhető lenne, erről részletesebben a "Reflekció újragondolása" szekcióban van írva. Lényege, hogy a jelenlegi, beépített osztályokon levő reflekciót le kellene cserélni interpretálása. Az alapok ehhez megvannak, viszont ez is egy komolyabb programozási feladat.

#### 3.4.4. További tesztelés

A szakdolgozat írása során megpróbáltam az alapos tesztelésre figyelni, ezért is vannak az alapvető instrukciót egyesével tesztelve (minden tesztfájl-ban külön-külön instrukciók szerepelnek). Viszont a tökéletes program nem létezik, elképzelhető hogy valahol nincs megfelelően a stack törölve, vagy valamely instrukció mégsem helyes. Tehát a programban elképzelhető a probléma. Ezt a még alaposabb teszteléssel minél inkább meg lehetne cáfolni.

Ehhez egy példa még több tesztfájl mellékelése. A tesztelő környezetbe (Python szkript) viszonylag egyszerűen be lehet helyezni új teszt fájlokat, amely leellenőrzi hogy megfelelő-e a program futása. Továbbfejlesztésként lehet Java programokat írni, majd ezeket a tesztelő környezethez hozzáadni, és ellenőrizni hogy jól fut-e le a program.

Egy másik érdekes továbbfejlesztés, hogy ne csak Java programokat írjunk, hanem más JVM-et felhasználó nyelvekben is írjunk programokat. Ezekkel ellenőrizhetjük hogy a program tényleg képes-e általános Java bájtkódot interpretálni, vagy csak limitált a Java programozási nyelvre. A témabejelentés miatt én az ezekkel a nyelvekkel való tesztelést kihagytam. Egy egyszerű "Hello, World!"-el való tesztelés során (Clojure/Kotlin/Scala nyelven) a program hibát fog dobni, ennek az indoka hogy a programban levő reflekció, mivel a program Java nyelven van írva, nem találja a Clojure/Kotlin/Scala függvényeket, ehelyett érdemes lenne minden egyes fájlt

interpretálni, nem csak a nem beépített osztályok fájlait. Természetesen ez megoldható ha a megfelelő nyelv standard könyvtárát be tudjuk másolni a cp parancssori zászlóval.

#### 3.4.5. Reflekció újragondolása

A reflekció egy viszonylag negatív hírrel rendelkező programozási folyamat, melynek számos indoka van, legtöbbször a fő indok az, hogy a reflekcióval megoldott problémát valamilyen elegánsabb módon is meg lehetne oldani.

Sajnos a szakdolgozat programjában is észrevehető hogy a reflekció nem annyira tökéletes megoldás erre a problémára, lehetne elegánsabb megoldást is találni. A reflekció túlságos használata miatt a teljesítmény is rosszabb, egy komoly optimalizálási feladat a programban lévő reflekciót lecserélni.

A másik komoly probléma a szakdolgozatban a reflekció használatával, az előbb említett képtelenség arra, hogy Java nyelven kívüli programokat futtatni tudjon. Habár a program készen áll arra, hogy ezeket futtatni tudja, a jelenlegi állapotában nem lehet. Ha minden egyes függvényt interpretálnánk, nem hagyakoznánk a reflekcióra, akkor egy univerzális interpretert lehetne írni, tehát egy Java nyelven íródott program képes lenne Clojure/Kotlin/Scala fordítóprogramok által generált class fájlokat interpretálni, lefuttatni.

#### 3.5. Érdekességek a JVM specifikációból

A specifikációt olvasva számos érdekességre bukkanhat az ember, ezek között vannak tervezési anomáliák, jó megoldások és trükkök. Ezek közül pár:

• A Java 7-es verzió előtt a Java bájtkód instrukciók viszonylag egyszerűek voltak, a 7-es verzióval lett az invokedynamic bevezetve, mely közelebbi ránézésre igazából egy "szuperinstrukció", ezzel az összes többi invoke instrukció implementálható, sőt, egy teljes Java bájtkód interpret is megírható csak invokedynamic utasításokkal. Az invokedynamic utasítás a dinamikusság kérdésére volt a válasz. Lényege, hogy azon függvényhívásokat, amelyek paramatéreit fordítási időben nem tudjuk, egy hívási helynek (CallSite) megfelelően kerülnek a JVM-be bele, amely az a hívás során a megfelelő paraméterekkel hívja meg.

- Elméletileg a lokális változók száma nem kéne hogy 65536 legyen. Ha megnézi az ember, akkor minden store és load utasítás egy darab 8 bites előjel-mentes számot olvas be paraméterként. Ez azt jelenti hogy összesen  $2^8 = 256$  lehetséges index kellene hogy legyen. A wide módosító utasítás miatt viszont ezek az utasítások beolvashatnak két darab 8 bites előjel-mentes számot, tehát lényegében egy darab 16 bites előjel-mentes szám lesz a paraméterük. Ez azt jelenti hogy 256 lehetőség hirtelen  $2^{16} = 65536$ -ra ugrik fel.
- Minden Long és Double típusú adattag két (egymást követő) helyet foglal el a class fájlon belüli Constant Pool-ban. Ennek oka hogy minden Constant Pool beli elem tényleges felhasználható adata 4 byte-on van, kívéve a Long és Double, amelyek felhasználható adatai 8 byte-on vannak. Így a fájlon belüli folytonosság miatt a specifikáció készítői jobbnak látták hogy inkább két helyet foglaljon el. A specifikációban azóta is a In retrospect, making 8-byte constants take two constant pool entries was a poor choice. Utólag visszagondolva, rossz döntés volt, hogy a 8 bájtos konstansok két konstans pool bejegyzést igényelnek. idézet áll.
- A Long és Double típusokhoz kapcsolódoan, egy hatalmas különbség a primitívek (double, long) és osztály (java.lang.Double, java.lang.Long) típusok között, hogy lokális változókként a primitívek (csak a double és long) két helyet foglalnak el a lokális változók között; míg az osztály típusok csak egy helyet. Ez azt jelenti, hogyha függvény paraméterként adunk át egy double primitívet, akkor valójában 2 helyet foglalunk el a lokális változók között, míg ha egy java.lang.Double értéket adunk át, csak egy 1 helyet fogunk elfoglalni.

# 4. fejezet

# Összegzés

Lorem ipsum dolor sit amet, consectetur adipiscing elit. In eu egestas mauris. Quisque nisl elit, varius in erat eu, dictum commodo lorem. Sed commodo libero et sem laoreet consectetur. Fusce ligula arcu, vestibulum et sodales vel, venenatis at velit. Aliquam erat volutpat. Proin condimentum accumsan velit id hendrerit. Cras egestas arcu quis felis placerat, ut sodales velit malesuada. Maecenas et turpis eu turpis placerat euismod. Maecenas a urna viverra, scelerisque nibh ut, malesuada ex.

Aliquam suscipit dignissim tempor. Praesent tortor libero, feugiat et tellus porttitor, malesuada eleifend felis. Orci varius natoque penatibus et magnis dis parturient
montes, nascetur ridiculus mus. Nullam eleifend imperdiet lorem, sit amet imperdiet
metus pellentesque vitae. Donec nec ligula urna. Aliquam bibendum tempor diam,
sed lacinia eros dapibus id. Donec sed vehicula turpis. Aliquam hendrerit sed nulla vitae convallis. Etiam libero quam, pharetra ac est nec, sodales placerat augue.
Praesent eu consequat purus.

# Köszönetnyilvánítás

Petes Márton (ELTE IK PTI BSc): Az elekadásaim során elképesztően sok segítséget nyújtott, nélküle nem tudom hogy meglett volna-e a szakdolgozat

# Irodalomjegyzék

[1] Gilad Bracha Tim Lindholm Frank Yellin és Alex Buckley. "The Java Virtual Machine Specification". (2013. febr.). URL: https://docs.oracle.com/javase/specs/jvms/se7/html/index.html.

# Táblázatok jegyzéke

3.1.	Erőforrás	különbségek	_																	_	_	_					_	_	19	_
0.1.	LIGIGIA	II di Oli Obo Soli	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	т,	,

# Forráskódjegyzék

2.1.	invokedynamic utasítást tartalmazó Java kód	6
3.1.	Példa a Main.class interpretálására	12
3.2.	${\bf A}$ Codeindex osztály, amely a kód bájttömb jelenlegi indexét tárolja .	15
3.3.	Az interpretálásért felelős kódrészlet	16